


基于 Newton 物理引擎与 Claude VLA 的具身智能交互演示

CPU-only 课堂级具身智能交互系统：经典控制 · 混合 VLA 解析 · 真实物理仿真



项目主页 · 在线演示

核心思想 Key Idea


大模型解析一句话需 2–10 s，远超 60 fps 的 16.7 ms 帧预算。本工作在时间上解耦“行动”与“推理”：确定性关键词预飞在 ~ 1 ms 内驱动机械臂，慢速 Claude (~ 9.4 s) 在后台线程精化并与之比较确认。

⇒ 观众感知延迟由 **9.4 s** 降至 **1 ms**——即时响应 + 智能补正。

9.4 s → 1 ms $\approx 40\times$ 60 fps 250

感知延迟 物理提速 CPU-only 测试

方法概览：延迟解耦的混合 VLA 解析管线



预飞与 Claude 并行；generation counter 保证过期线程不覆盖新命令。

贡献 Contributions


- 混合 VLA 解析管线——预飞 + 后台精化 + generation counter，将慢速大模型嵌入实时机器人闭环（感知延迟 9.4 s → 1 ms）。
- KINEMATIC ↔ DYNAMIC 抓取——在无 weld 约束的 XPBD 上实现夹爪抓取。
- 物理步进 **11.9 → 0.30 ms ($\approx 40\times$)**——揭示瓶颈为内核启动开销而非算力。
- 偏移塔稳定性实验——理论判据与真实 XPBD 实测边界的诚实对照。

引言与动机

大语言模型已能写代码、规划、对话，但“身体”仍是缺失的一环。课堂场景中学生难以直观区分经典控制与学习驱动，亦难以亲手验证大模型在闭环物理中的行为。本系统将二者并置于同一可交互画面，降低具身智能教学的硬件与认知门槛。

三种交互模式

- 接球——单步闭式弹道反解（经典控制，无 AI）；固定种子自动基准命中 92–100%。
- 自然语言驱动——LLM 意图解析器（L → A，无像素输入），区别于 RT-2 式端到端 VLA。
- 装饰手势——wave / point / bow / dance。



接球：蓝色轨迹采样 + 橙色截击圆环，每帧 1 ms 内闭式解算。


系统架构

五层单向数据流：输入 → 解析 (vla/voice/pipeline) → 控制 (tasks/control/catcher) → 物理 (Newton XPBD) → 渲染 (scene/effects)；telemetry 横切各层写 CSV。22 模块、约 7730 行。关注点分离使解析层可替换大模型而不影响下游。


方法细节

- 预飞命中即将程序推入执行器队列，机械臂当帧启动；
- Claude 在后台 daemon 线程返回后与预飞比较：相同则静默确认，不同则记录；
- 每次派发递增 generation 计数，worker 仅在计数匹配时写回，杜绝过期覆盖。

演示流程（连续运行实录）



实验：偏移塔稳定性（理论 vs 仿真）



逐层偏移 0 / 4 / 9 cm：稳 · 稳 · 倒（重心铅垂线越界变色）

刚体理想判据 $1.5d > r \Rightarrow d > 6.67$ cm；真实 XPBD 实测倒塌边界落在 (4, 5] cm（接触柔度使其更早失稳）。三档稳/倒与理论同号，倒塌由求解器判定。

性能评估

world.step() 原占 11.9 ms (71% 帧预算)，主体为 Warp 内核启动开销而非计算。经降迭代/子步与 teleport 跳过碰撞等优化降至 **0.30 ms ($\approx 40\times$)**，uncapped 吞吐 64 → **279 fps**。渲染臂由控制器前向运动学驱动，降迭代对画面无影响。

评估与结论

250 项单元与集成测试（100% 通过），偏移塔倒塌边界由真求解器回归测试固定。系统在无 GPU、无云的消费级硬件上实现了可解释、低延迟、可复现的具身智能教学演示。

项目主页 hollis36.github.io/newton-vla-demo

源码 github.com/Hollis36/newton-vla-demo (MIT, v0.2.0)