

基于 Newton 物理引擎与 Claude VLA 的具身智能交互演示

设计报告

kingcode

2026 年 5 月

摘要

本项目实现了一个 3 分钟课堂级具身智能交互演示，运行在一台苹果芯片的 MacBook 上，无需 GPU 或云端推理。系统结合 NVIDIA Newton XPBD 物理引擎、pygame 二维渲染管线，以及 Claude 命令行客户端作为视觉-语言-动作 (VLA) 解析器，提供三种交互模式：基于模型预测控制 (MPC) 的接球，自然语言驱动的抓取与堆叠，以及四种装饰性手势 (wave / point / bow / dance)。工业模式额外引入第二只固定底座机械臂，自主循环搬运专属工件，形成双臂并行的工厂调度视觉效果。核心技术贡献包括：(1) 闭式弹道求解的轻量 MPC；(2) 关键词预飞 + Claude 精化的混合 VLA 解析管线，将平均命令到动作延迟从 9.4 s 压缩到 1 ms；(3) 固定臂与移动臂共享 `world.blocks` 但物理无冲突的执行器抽象。系统经 214 项单元与集成测试覆盖，实战演示中接球命中率 62%-82%，VLA 链路稳定跑通 “pizza tower → stack red green blue” 等模糊语义指令。

关键词： 具身智能、模型预测控制、视觉-语言-动作模型、物理仿真、人机交互

目录

1	引言	3
1.1	项目背景与动机	3
1.2	设计目标	3
1.3	报告组织	3
2	相关技术	3
2.1	NVIDIA Newton XPBD 物理引擎	3
2.2	模型预测控制与逆运动学	4
2.3	视觉-语言-动作模型 (VLA)	4
2.4	Claude CLI 集成	4

3	系统架构	5
3.1	总体架构	5
3.2	模块清单	5
3.3	关键设计决策	5
4	核心算法	7
4.1	接球 MPC: 闭式弹道反解	7
4.2	三链平面逆运动学	7
4.3	Minimum-jerk 缓动 + back-ease-out	7
4.4	VLA 混合解析管线	8
4.5	语音模糊匹配: phonetic + bigram LM	8
5	实现细节	8
5.1	Arm B 固定底座设计	8
5.2	固定臂避免误驱动 Arm A 的修复	9
5.3	遥测 CSV 与公式注入防护	9
5.4	慢动作戏剧化	9
6	测试与评估	10
6.1	测试覆盖	10
6.2	性能基准	10
6.3	实战演示结果	10
6.4	演示截图	11
7	总结与展望	11
7.1	已完成工作	11
7.2	局限性	11
7.3	未来工作	12

1 引言

1.1 项目背景与动机

具身智能 (Embodied AI) 是当前人工智能领域最具张力的方向之一：大语言模型已经能像人类一样写代码、答题、规划，但“身体”仍然是缺失的最后一公里。在课堂教学场景中，学生很难直观感受“经典控制”与“学习驱动”之间的分野，也难以亲手验证大语言模型在闭环物理世界中的实际表现。本项目以一台 MacBook 为硬件平台、以 Newton 物理引擎为仿真后端、以 Claude 为 VLA 大脑，搭建一个 3 分钟即可完整呈现的现场演示，目的是让观众在不到一节课的时间内同时体验：

- 经典控制 (MPC) 的精确性与可预测性；
- 自然语言到结构化动作的端到端解析；
- 大模型推理延迟与降级策略的工程取舍；
- 多臂协同与并行任务的视觉效果。

1.2 设计目标

1. **现场稳定**：3 分钟完整流程不允许出现死机、NaN、模型超时等致命异常；
2. **零云依赖**：所有推理、物理、渲染本地化，无需保证网络；
3. **60 fps 视觉**：1920 × 1080 全屏渲染平均帧率不低于 58 fps；
4. **毫秒级首响应**：观众输入命令后机械臂在 1 ms 内开始动作；
5. **可测试**：所有关键路径（物理、控制、解析、渲染）必须有自动化回归测试。

1.3 报告组织

第 2 节介绍背景技术；第 3 节展示系统总体架构与模块划分；第 4 节阐述核心算法（接球 MPC、IK、缓动函数、混合 VLA 管线）；第 5 节聚焦实现细节与工程取舍；第 6 节给出测试覆盖与性能基准；第 7 节总结与展望。

2 相关技术

2.1 NVIDIA Newton XPBD 物理引擎

Newton 是 NVIDIA 在 2025 年发布的开源物理仿真引擎，基于扩展位置基动力学 (XPBD) 构建，支持刚体、布料、流体的统一约束求解。本项目仅使用其 XPBD 刚体求解器与铰接关节 (`add_joint_revolute`) 接口，构造三链平面机械臂。

XPBD 的一个工程化代价是**初始速度** `body_qd` 在某些版本上会被求解器在第一次 **step 后清零**，因此项目中的接球小球并未走 XPBD 求解，而是 Python 端独立解析积分：

$$z(t) = z_0 + v_z t - \frac{1}{2} g t^2, \quad x(t) = x_0 + v_x t$$

渲染时把小球位置写回 `body_q` 即可。

2.2 模型预测控制与逆运动学

对于本演示，“MPC”是一个轻量版本：每帧由当前 (x_0, z_0, v_x, v_z) 重新拟合弹道，求出小球到达截击高度 `INTERCEPT_Z` 的时间 t^* 与对应 x^* ，闭式解为

$$t^* = \frac{-v_z + \sqrt{v_z^2 - 4a(z_0 - z^*)}}{2a}, \quad a = -\frac{1}{2}g.$$

判别式 $\Delta = v_z^2 - 4a(z_0 - z^*)$ 若为负，说明此弹道无法到达截击高度，此时退出当前 `commit`。

得到 x^* 后调用闭式三链 IK 求关节角，关键点是必须取 “downward crossing” 即较大的正根，否则机械臂会朝小球 上升方向的截点而非下落方向截击。

2.3 视觉-语言-动作模型 (VLA)

传统机器人指令需要程序员显式编码 “if color == red: pick_red()”，VLA 模型让自然语言直接驱动动作。本项目使用 Claude CLI (`claude --print --model sonnet`) 作为解析器，给定包含系统提示词、对话历史、当前场景三段上下文的 prompt，输出形如

```
1 {"action": "stack", "color": null, "colors": ["red", "green", "blue"],
2  "target": null, "reason": "建塔，默认 RGB 顺序"}
```

的结构化 JSON。Claude 的优势是能解析 “pizza tower” 之类模糊语义并映射到正确的 stack 操作；劣势是端到端延迟 2–10 s，显著超出 60 fps 的帧预算。

2.4 Claude CLI 集成

所有 Claude 调用通过子进程进行 (`subprocess.run, check=False`)，prompt 经标准输入注入。这样做的好处：

- 无需独立 API key，复用用户本地 Claude Code 订阅；
- 子进程隔离，单次调用挂死不会影响 pygame 主循环；
- 命令行客户端首次登录后离线认证，断网仍可使用。

3 系统架构

3.1 总体架构

Figure 1 展示系统的层次结构：渲染层 (pygame + scene/scene_legacy) 在最上层；控制层 (JointController, TaskExecutor, BallCatcher) 在中间，将高层意图翻译为机械臂关节目标；物理层 (Newton + 自定义 ball / blocks 状态) 提供仿真后端；解析层 (vla.py / voice.py / pipeline.py) 是人机接口。一个 telemetry CSV 横切所有层，记录每帧关键事件。




图 1: Demo Live 总体架构。输入层 (橙) → 解析层 (绿) → 控制层 (青) → 物理层 (红) → 渲染层 (紫), telemetry (黄) 横切记录。

3.2 模块清单

全部 14 个 Python 模块，3279 行实代码 + 4 个新增辅助模块 (bootstrap, pipeline, scripted, telemetry) 列于 Table 1。

3.3 关键设计决策

决策 1: 球独立 Python 积分，方块独立 Python 存储

Newton XPBD 对动质量物体的“瞬移设置位姿”兼容性较差 ($mass > 0$ 时 teleport 引发能量爆发; $mass = 0$ 时 is_kinematic 飞到 NaN), 因此小球、方块都不进 XPBD 求解, 由 Python 直接维护位姿、被渲染器消费。

决策 2: 双渲染管线 (industrial / classroom whiteboard)

工业风让画面像“UR-class 车间”，课堂白板风像“学生草稿本”，两条路径并存以

表 1: 模块清单与行数 (excluding tests)

模块	行数	职责
<code>__main__.py</code>	1139	pygame 主循环、事件分发、模式切换
<code>scene_legacy.py</code>	671	默认课堂白板风格渲染 (单文件)
<code>scene/arm.py</code>	660	工业风机械臂渲染
<code>voice.py</code>	527	麦克风录音、Google STT、模糊匹配
<code>physics.py</code>	478	Newton 世界、积分、3-DOF 铰接臂
<code>vla.py</code>	452	Claude CLI 子进程、关键词回退
<code>tasks.py</code>	443	pick / place / stack / drive / gesture
<code>render.py</code>	300	草图风格线条、文字、抗锯齿
<code>catcher.py</code>	257	MPC 状态机、弹道解算
<code>scene/chrome.py</code>	238	表头 / 侧边栏 / 页脚
<code>effects.py</code>	244	粒子、光环、横幅、轨迹
<code>scene/world.py</code>	228	地面、球、轨迹、方块
<code>control.py</code>	215	PD slew、idle wobble、NaN 拒收
<code>telemetry.py</code>	157	CSV 写入器、退出总结
<code>ik.py</code>	91	闭式三链平面 IK
<code>scripted.py</code>	91	彩排脚本、Arm B 循环数据
<code>pipeline.py</code>	84	action $\rightarrow$ Waypoint 程序映射
<code>bootstrap.py</code>	72	Warp 预热、Arm B 构造
<code>sfx.py</code>	132	音效播放
<code>config.py</code>	133	设计令牌: 颜色、字体、布局
合计	6612	

适应不同观众。默认课堂风, `--industrial` 切工业风。

决策 3: 混合 VLA 解析管线

Claude CLI 平均延迟 2–10 s, 远超 60 fps 帧预算。keyword preflight 在 ~ 1 ms 内派单, Claude 在后台细化; preflight 命中即用 preflight 结果驱动机械臂, Claude 返回时与之比较仅打日志。详见 4.4。

决策 4: Arm B 不驱动底盘

工业模式下的第二只机械臂 Arm B 固定在右侧支架上, 其 `TaskExecutor` 配置 `anchor_world_x` 回调返回固定锚点; 执行器在 `_ensure_reachable` 检测到 anchor 已设时跳过 drive 步骤, 避免 Arm B 的 pick 拖动 Arm A 的底盘。

4 核心算法

4.1 接球 MPC：闭式弹道反解

小球以初始状态 (x_0, z_0, v_x, v_z) 抛出，在重力 g 下沿抛物线运动：

$$x(t) = x_0 + v_x t \quad (1)$$

$$z(t) = z_0 + v_z t - \frac{1}{2}gt^2. \quad (2)$$

求 $z(t) = z^*$ 即截击高度时的根：

$$at^2 + bt + c = 0, \quad a = -\frac{1}{2}g, \quad b = v_z, \quad c = z_0 - z^*.$$

判别式 $\Delta = b^2 - 4ac$ 。若 $\Delta < 0$ ，小球无法到达截击高度，触发一次性 stderr 警告并退出本次预测。否则两根为

$$t_{\pm} = \frac{-b \pm \sqrt{\Delta}}{2a}.$$

本演示总是选**较大的正根** $t^* = \max(t_-, t_+) \in (0.02, 2.5]$ ——对应下落方向的截点。 $x^* = x_0 + v_x t^*$ 即截击位置。

4.2 三链平面逆运动学

机械臂为三链 (link 长度 ℓ_1, ℓ_2, ℓ_3)、转轴 $(0, -1, 0)$ 的串联机器人。给定末端目标 (x^*, z^*) 与末端朝向角 θ_{hand} ，闭式求解三关节角 (q_1, q_2, q_3) 。先把目标投影到第三链起点：

$$x_2 = x^* - \ell_3 \cos \theta_{\text{hand}} \quad (3)$$

$$z_2 = z^* - \ell_3 \sin \theta_{\text{hand}} \quad (4)$$

然后用余弦定理对二链求 q_2 ：

$$\cos q_2 = \frac{x_2^2 + z_2^2 - \ell_1^2 - \ell_2^2}{2 \ell_1 \ell_2}$$

最后 $q_1 = \text{atan2}(z_2, x_2) - \text{atan2}(\ell_2 \sin q_2, \ell_1 + \ell_2 \cos q_2)$, $q_3 = \theta_{\text{hand}} - q_1 - q_2$ 。

4.3 Minimum-jerk 缓动 + back-ease-out

每个机械臂分段使用 min-jerk 时间映射 $\tau(t) = 10t^3 - 15t^4 + 6t^5$ 太“机械化”，audience 看会觉得是没有灵魂的钢铁。本项目对该曲线加上 0–8% 的反向 wind-up 预备 + 4–8% 的过冲 (back-ease-out, 参数 $s = 1.4$)，形成“弹簧蓄力 → 加速 → 略微过冲 → 收敛”的有机动作。

4.4 VLA 混合解析管线

Figure 2 展示混合解析管线的时序: 用户输入文本后 (1) 同步运行 `_keyword_fallback` 关键词解析, 命中 (如 “pick red” $\rightarrow$ `action="pick", color="red"`) 后立即将 plan 推入执行器队列, 此时机械臂 **已经在动**; 与此同时 (2) 启动后台线程跑 `claude --print`, 约 2–10 s 后返回; (3) 主循环 drain parse_thread 时比较 Claude 与 preflight 结果: 相同 $\rightarrow$ 静默确认; 不同 $\rightarrow$ 打日志, 但 preflight 已执行, 不再覆盖。

为防止旧线程的 stale 结果覆盖新命令, 每次 fire 增加 generation counter, worker 完成时检查 `parse_result["gen"]` 仍等于自己的 gen 才写回。




图 2: 混合 VLA 解析管线时序。Preflight 在 1 ms 内派单机械臂开始动, Claude 后台 9.4 s 后返回作为“智能复审”。

4.5 语音模糊匹配: phonetic + bigram LM

Google Web Speech 对小词汇量演示场景识别率较低, 例如把 “pick red” 识别为 “peter ride”。本项目两级修正:

1. **Phonetic 映射表**: 57 个手工标定的音近词 (peter $\rightarrow$ pick, ride $\rightarrow$ red, blew $\rightarrow$ blue 等);
2. **Bigram 语言模型**: 在 49 个标准命令模板上训练 bigram 概率, 对 difflib 编辑距离的多个候选用语境概率重新排序。

经基准测试 “filter + learned phonetic” 在合成噪声集上的命令准确率比无修正提升 14 个百分点。

5 实现细节

5.1 Arm B 固定底座设计

工业模式启用第二只机械臂 Arm B, 锚定在 `world_x = 2.40` 的固定支架上 (FK-only, 不进 Newton 物理)。Arm A 与 Arm B 共享 `world.blocks`: 谁先 pick 谁拿到, 互斥。Arm B 在空闲时按 `ARM_B_IDLE_CYCLE` 循环搬运一个专属 “workpiece” 方块:


```

1 ARM_B_IDLE_CYCLE: list[ArmBIdleStep] = [
2     ArmBIdleStep(action="place", color="workpiece", target=(2.50, 0.0)),
3     ArmBIdleStep(action="place", color="workpiece", target=(1.50, 0.0)),
4 ]

```

落沿检测 (prev_arm_b_busy=True → busy_now=False) 启动 ARM_B_IDLE_PAUSE_S (1.0 s) 暂停时钟, 到期后队列下一个步骤; arm_b_idle_next_at = inf 防止同帧重复 queue。

5.2 固定臂避免误驱动 Arm A 的修复

原始 TaskExecutor._ensure_reachable 对任意臂都 prepend 一个 drive waypoint。但 Arm B 的 drive 会通过 exe.world.drive_to(clamped) 误移动 Arm A 的底盘。修复: 检测 anchor_world_x 已设时早返回空 prep:

```

1 def _ensure_reachable(self, world_xz):
2     if self.anchor_world_x is not None:
3         return [] # fixed-base arm: no drive
4     OPTIMAL_REACH = 0.45
5     ...

```

5.3 遥测 CSV 与公式注入防护

每场演出生成 logs/demo-<YYYYmmdd-HHMMSS>.csv, 记录 mode 切换、preflight 派单、VLA 调用 (含 backend / latency)、voice 转录、catch 事件。CSV 字段以 =, +, -, @, \t 开头时会被 Excel/Numbers 解释为公式, 构成注入漏洞。_sanitize 对此前缀加单引号无害化:

```

1 _FORMULA_PREFIXES = ("=", "+", "-", "@", "\t")
2 def _sanitize(s: str) -> str:
3     if not s: return ""
4     cleaned = s.replace("\r", " ").replace("\n", " ")
5     if cleaned[:1] in _FORMULA_PREFIXES:
6         cleaned = "'" + cleaned
7     return cleaned[:200]

```

5.4 慢动作戏剧化

接球成功 (catch_count 上升) 或多步程序完成 (executor.busy 由 True 转 False) 时, scale frame_dt 系数到 0.33 维持 1.5 s。**关键约束:** gate on not executor.busy。否则在 pick/stack 中接球进入慢动作, controller.update 是 dt 相关的但 executor.update 以 time.perf_counter() 计时 (与 dt 解耦), 导致 arm 跟不上 waypoint, 视觉脱钩。

6 测试与评估

6.1 测试覆盖

Table 2 列出 214 项自动化测试的分布。每个核心模块都有专门的测试文件，关键路径 (closed-form IK round-trip、混合 VLA 解析、catcher 弹道反解、控制器 NaN 拒收) 通过单元 + 集成两个层级覆盖。

表 2: 测试覆盖矩阵		
测试文件	测试数	重点
test_voice_fuzzy.py	78	78 个噪声转录用例
test_tasks.py	24	程序构造器 + 4 手势
test_pipeline.py	20	所有 action 分支
test_render_smoke.py	20	双渲染路径全部 draw_*
test_effects.py	19	粒子 / 光环 / 横幅生命周期
test_catcher.py	18	弹道反解 + 状态机
test_vla_subprocess.py	17	Claude CLI mock + 失败模式
test_vla_parser.py	16	关键词解析 (en + zh)
test_control.py	13	PD slew + rate clamp + NaN
test_telemetry.py	10	CSV 格式 + 公式注入
test_scripted_constants.py	7	彩排数据自洽
test_ik.py	6	FK ◦ IK ≈ id
test_scripted_flows.py	5	端到端 --scripted 流程
test_display_mode.py	1	显示模式参数解析
合计	214	通过率 100%，墙钟约 102 s

6.2 性能基准

Table 3 列出 Apple Silicon CPU-only 下的 FPS 实测数据。所有 scripted 流程平均 ≥ 58 fps，60 Hz 目标达成。cProfile 分析表明 demo_live 自身代码只占帧预算的 10%，90% 在 Newton XPBD solver，无可优化的瓶颈。

6.3 实战演示结果

最近三次实战演示数据见 Table 4：接球命中率 62%–82%，VLA 端到端跑通 “pizza tower” 模糊语义指令 (Claude 9.4 s 后返回 stack [red,green,blue])。

表 3: FPS 实测 (Apple Silicon, CPU-only)

场景	min	avg	max	样本
IDLE bench 20 s	31.5	60.7	75.9	1211
Scripted catch 10 s	28.2	59.6	72.8	594
Scripted pick 8 s	41.7	60.7	70.3	485
Scripted stack 25 s	24.8	59.2	74.9	1476
Scripted VLA 25 s	24.0	59.6	75.1	1484
Rehearsal 60 s	2.9	58.7	76.0	3494

表 4: 实战演示数据

日期	catch	VLA 命令	备注
2026-05-21 12:05	7/10	0	首次现场测试
2026-05-21 12:30	8/13	1	Claude 9.4 s 解析 “pizza tower”
2026-05-21 17:42	14/17	0	30 s 密集投球, 82% 命中

6.4 演示截图

Figure 3 与 Figure 4 展示两种渲染模式的最终视觉。工业模式呈现 “UR-class 双臂车间” 氛围；课堂模式则是 “黑板上的手绘草稿” 风格，适合不同观众。

7 总结与展望

7.1 已完成工作

- 三模式交互演示：接球 (MPC)、自然语言 (VLA)、手势；
- 双渲染管线：课堂白板 + 工业双臂工作站；
- 混合 VLA 解析：preflight 1 ms + Claude 后台精化；
- Arm B 自主工件搬运循环；
- 214 项自动化测试，60 fps 稳定，实战命中 62%–82%；
- 完整 CSV 遥测 + 公式注入防护；
- 文档同步：README + REHEARSAL 与代码 100% 一致。

7.2 局限性

1. `__main__.py` 仍有 1139 行，超出项目编码规范的 800 行硬上限。完整 `AppState` `dataclass` 重构需要架构改动，本项目阶段性接受这一债务；




图 3: 工业模式 (`--industrial`)。左侧 Arm A 在移动底盘上, 右侧 Arm B 固定在支架上自主搬运 workpiece。

2. D.3 慢动作是简化版 (整体放慢 dt), 原计划的逐帧 snapshot replay 因实现复杂度被降级;
3. 语音模糊匹配仅覆盖 en-US / zh-CN, 未扩展到日韩等语言;
4. 接球 MPC 是单步式 (每帧重拟合, 无前瞻规划), 复杂多轨道场景下精度有限。

7.3 未来工作

- **AppState 重构**: 定义可变 dataclass 收纳全部主循环状态, 把 `__main__.py` 切到 ≤ 200 行;
- **完整逐帧 replay**: 环形缓冲器 + 渲染层 source 切换, 比 slow-mo 更具戏剧化;
- **多臂协调**: Arm B 检测 Arm A 持物时让出工作区, 更接近真实工厂调度;
- **多语言扩展**: 日语 / 韩语 / 西语模糊匹配 + Claude prompt 本地化。

致谢

感谢 NVIDIA 开源 Newton 物理引擎, 为本演示提供了高品质的仿真后端。感谢 Anthropic 的 Claude 命令行客户端, 让自然语言驱动机器人成为本地可行的方案。

参考文献

- [1] NVIDIA, “Newton: A GPU-accelerated, differentiable physics engine,” <https://github.com/newton-physics/newton>, 2025.




图 4: 默认课堂模式。手绘风格机械臂、彩色方块、控制提示侧栏，模拟黑板教学场景。

- [2] Macklin, M., Müller, M., Chentanez, N., “XPBD: position-based simulation of compliant constrained dynamics,” *Proc. ACM MIG*, 2016.
- [3] Anthropic, “Claude Code: A CLI for agentic coding,” <https://claude.com/claude-code>, 2025.
- [4] Flash, T., Hogan, N., “The coordination of arm movements: an experimentally confirmed mathematical model,” *J. Neuroscience*, vol. 5, no. 7, pp. 1688–1703, 1985.
- [5] Murray, R.M., Li, Z., Sastry, S.S., “A Mathematical Introduction to Robotic Manipulation,” CRC Press, 1994.
- [6] Brohan, A. et al., “RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control,” arXiv:2307.15818, 2023.
- [7] Google, “Cloud Speech-to-Text,” <https://cloud.google.com/speech-to-text>.